

Filière : Intelligence Artificielle & Data Science (IADATA)

Année Universitaire : 2025/2026

CAHIER DES CHARGES

Projet Big Data

Collecte et Analyse de Données Livres

Web Scraping · Data Lake · Architecture Médaillon · Visualisation

Réalisé par :

El Mouden Badre
Nisrine Ragragui
Bouthaina Bouargane

Encadré par :

Mme Lamia Karim

Référence	: CDC-BIGDATA-BOOKS-2026
Date de rédaction	: Avril 2026
Date limite de rendu	: 10 Mai 2026 à Minuit
Filière	: IADATA – 4ème année

“De la donnée brute à la décision analytique”

Remerciements

Nous tenons à exprimer notre profonde gratitude à toutes les personnes qui ont contribué à la réalisation de ce projet Big Data.

À notre encadrant pédagogique,

Madame Lamia Karim, pour ses précieux conseils, sa disponibilité et son accompagnement tout au long de ce projet. Ses orientations avisées nous ont permis de structurer notre réflexion et de mener à bien cette réalisation.

À l'équipe pédagogique de l'EMSI Casablanca,

et plus particulièrement au département IADATA, pour la qualité de la formation dispensée et les ressources mises à disposition.

Aux contributeurs techniques,

Aux communautés open source derrière Apache Airflow, Scrappy, MinIO, Streamlit, Power BI et Great Expectations, dont les outils ont rendu ce projet possible.

Aux sources de données,

Books to Scrape (books.toscrape.com) et Open Library (openlibrary.org) pour la mise à disposition gratuite de leurs catalogues et APIs, essentiels à notre chaîne de collecte.

Enfin, à nos familles et proches,

pour leur soutien indéfectible et leur patience durant les longues heures de travail consacrées à ce projet.

Table des matières

Remerciments	1
Introduction	6
1 Présentation du Projet	7
1.1 Contexte	7
1.2 Problématique	7
1.3 Objectifs	7
2 Architecture Générale du Système	8
2.1 Vue d'ensemble	8
2.2 Schéma du pipeline	9
2.3 Stack Technique	9
3 Collecte de Données – Web Scraping	10
3.1 Sources de données	10
3.2 Données collectées	10
3.3 Spécifications du scraper	11
3.4 Format de sortie brut (Bronze)	11
4 Ingestion des Données	12
4.1 Mode Batch	12
4.2 Mode Streaming	12
5 Infrastructure Docker	13
5.1 Composition des services	13
5.2 Commandes essentielles	14
5.3 Interfaces web	14
6 Data Lake – MinIO	15
6.1 Organisation des buckets	15
7 Architecture Médaillon	16
7.1 Schéma des couches	16
7.2 Couche Bronze – Données Brutes	16
7.3 Couche Silver – Données Nettoyées	16
7.3.1 Score de qualité	17
7.3.2 Gestion de la quarantaine	17
7.4 Couche Gold – Tables Analytiques	17

8	Orchestration – Apache Airflow	18
8.1	DAG unique implémenté	18
8.2	Tâches du DAG	18
8.3	Orchestration du DAG	19
8.4	Récapitulatif du DAG	20
8.5	Monitoring et alertes	21
8.6	Tests de qualité	22
9	Visualisation – Streamlit & Power BI	23
9.1	Introduction	23
9.2	Dashboards réalisés	23
9.3	Dashboards Streamlit	24
9.4	Dashboards Power BI	26
10	Planning Indicatif	29
	Conclusion	30
	Bibliographie	31

Table des figures

2.1	Architecture générale de la plateforme Big Data	8
2.2	Pipeline de collecte et ingestion	9
5.1	Infrastructure conteneurisée	13
6.1	Interface MinIO Console après initialisation	15
7.1	Architecture Médaillon Bronze/Silver/Gold	16
8.1	Interface web Apache Airflow – Vue du DAG <code>pipeline_books</code>	21
8.2	Interface web Apache Airflow	21
9.1	Dashboard Streamlit BookFlow – Vue d’ensemble des KPIs	24
9.2	Dashboard Streamlit BookFlow – Top Livres les Plus Chers et Catalogue Complet	25
9.3	Power BI – Page principale : KPIs et catalogue des titres	26
9.4	Power BI – Page analyse par catégorie : notes, prix et volumes	27
9.5	Power BI – Page analyse par auteur : répartition et avis	28

Liste des tableaux

2.1	Technologies retenues	9
3.1	Sources de données ciblées	10
3.2	Schéma des données collectées	10
4.1	Comparaison Batch vs Streaming	12
5.1	Services Docker définis	13
5.2	Interfaces web disponibles	14
6.1	Structure du Data Lake MinIO	15
7.1	Calcul du score de qualité	17
7.2	Tables Gold produites	17
8.1	Tâches du DAG <code>pipeline_books</code>	19
8.2	Ordre d'exécution des étapes	19
8.3	Récapitulatif des propriétés du DAG	20
8.4	Tests de qualité des données	22
9.1	Dashboards réalisés dans BookFlow	23
10.1	Planning prévisionnel	29

Introduction

Le présent cahier des charges s'inscrit dans le cadre du module Architecture de Données de la filière Intelligence Artificielle & Data Science (IADATA) à l'EMSI Casablanca. Il a pour objectif de définir l'ensemble des spécifications techniques et fonctionnelles nécessaires à la réalisation d'une plateforme Big Data complète dédiée à la collecte automatique de données livresques.

L'édition numérique connaît une croissance exponentielle : des millions de titres sont référencés sur des plateformes de vente en ligne, des librairies numériques et des sites de critiques. Ces données constituent une mine d'informations précieuse pour analyser les tendances du marché du livre, identifier les genres les plus populaires, détecter des anomalies tarifaires ou encore comparer l'offre entre différentes sources.

Ce document détaille l'architecture proposée, les technologies retenues, les livrables attendus ainsi que le planning de réalisation.

1 Présentation du Projet

1.1 Contexte

L'édition numérique connaît une croissance exponentielle : des millions de titres sont référencés sur des plateformes de vente en ligne, des librairies numériques et des sites de critiques. Ces données — prix, notes, genres, avis, disponibilité — constituent une mine d'informations précieuse pour analyser les tendances du marché du livre, identifier les genres les plus populaires, détecter des anomalies tarifaires ou encore comparer l'offre entre différentes sources.

1.2 Problématique

Comment collecter, stocker, transformer et analyser à grande échelle des données hétérogènes issues de sites web de livres, afin d'en extraire des tendances, des indicateurs de marché et des insights décisionnels, tout en garantissant la qualité, la gouvernance et la traçabilité des données tout au long du pipeline ?

1.3 Objectifs

La plateforme doit permettre de :

1. Collecter automatiquement des données livresques (titres, auteurs, prix, notes, genres, disponibilité...) par scraping web.
2. Ingérer ces données en mode batch (planifié) et en mode streaming (événementiel).
3. Stocker les données brutes dans un Data Lake (MinIO).
4. Appliquer l'architecture Médaillon (Bronze → Silver → Gold) pour nettoyer et enrichir les données.
5. Orchestrer l'ensemble des pipelines avec Apache Airflow.
6. Charger les données analytiques dans un Data Warehouse pour l'analyse décisionnelle.
7. Produire des tableaux de bord interactifs visualisant les tendances et KPI du marché du livre.
8. Assurer la qualité, la gouvernance et la traçabilité des données.

2 Architecture Générale du Système

2.1 Vue d'ensemble

La plateforme s'articule autour d'un pipeline de traitement de données en plusieurs couches, conforme aux meilleures pratiques Big Data actuelles.




FIGURE 2.1 – Architecture générale de la plateforme Big Data

2.2 Schéma du pipeline

Le pipeline complet est représenté ci-dessous avec le détail des flux entre les différentes couches.




FIGURE 2.2 – Pipeline de collecte et ingestion

2.3 Stack Technique

Composant	Technologie	Version recommandée
Scraping	Python + Scrapy	Python 3.11, Scrapy 2.11
Message Broker	Apache Kafka	Kafka 3.6 (Bitnami Docker)
Data Lake	MinIO	MinIO RELEASE.2024
Transformation	Pandas	Pandas 2.x
Orchestration	Apache Airflow	Airflow 2.9
Data Warehouse	Mysql	MySQL 8.0
Visualisation	Streamlit & Power BI	Streamlit 1.35+, Power BI Desktop
Conteneurisation	Docker + Docker Compose	Docker 26+

TABLE 2.1 – Technologies retenues

3 Collecte de Données – Web Scraping

3.1 Sources de données

Catégorie	Sites / Sources	Type de données
Librairie en ligne	(books.toscrape.com)	Titres, prix, notes, disponibilité, genre
Catalogue d'academie	(openlibrary.org)	Auteur, langue, année, description, catégorie

TABLE 3.1 – Sources de données ciblées

3.2 Données collectées

Pour chaque livre, les champs suivants sont extraits :

Champ	Description	Exemple
titre	Titre complet du livre	The Great Gatsby
auteur	Nom de l'auteur	F. Scott Fitzgerald
prix	Prix affiché sur le site (£ ou \$)	£12.99
note_etoiles	Note de 1 à 5 étoiles	4
disponibilite	Stock disponible ou non	In Stock
categorie	Catégorie littéraire	Fiction
description	Résumé ou synopsis	A novel about the...
isbn	Identifiant ISBN-13	978-0743273565
langue	Langue de publication	English
annee_publication	Année de parution	1925
nb_avis	Nombre d'avis/critiques	1247
source	Site web d'origine	books.toscrape.com
url	URL de la page du livre	https://books.toscrape.com/...
date_scraping	Horodatage de la collecte	2026-04-10T08:30:00Z

TABLE 3.2 – Schéma des données collectées

3.3 Spécifications du scraper

Le scraper doit implémenter les fonctionnalités suivantes :

1. **Pagination automatique** : parcours de toutes les pages du catalogue.
2. **Navigation par catégorie** : scraping de chaque genre de façon indépendante.
3. **Extraction de la fiche détaillée** : accès à chaque page individuelle de livre.
4. **Gestion des erreurs** : retry automatique (max 3 tentatives), logging.
5. **Déduplication** : vérification de l'URL via Redis avant scraping.
6. **Anti-blocage** : rotation de User-Agents, délais aléatoires, proxies rotatifs.

3.4 Format de sortie brut (Bronze)

Listing 3.1 – Exemple de donnée brute JSON

```
1 {  
2   "titre": "A Light in the Attic",  
3   "auteur": "Shel Silverstein",  
4   "prix": " 51 .77",  
5   "note_etoiles": 3,  
6   "disponibilite": "In stock",  
7   "categorie": "Poetry",  
8   "description": "It's hard to imagine a world without...",  
9   "isbn": "9780316769174",  
10  "url": "https://books.toscrape.com/catalogue/a-light-in-the-  
    attic_1000/",  
11  "source": "books.toscrape.com",  
12  "date_scraping": "2026-04-10T08:30:00Z"  
13 }
```

4 Ingestion des Données

Critère	Batch	Streaming
Déclenchement	Toutes les heures (Airflow)	Continu (Kafka producer)
Volume	~1 000 livres / run	1 event par livre
Latence	Jusqu'à 60 min	< 5 secondes
Format	JSON partitionné (MinIO)	Events Kafka → MinIO

TABLE 4.1 – Comparaison Batch vs Streaming

4.1 Mode Batch

Le scraping batch est déclenché automatiquement toutes les heures via Apache Airflow. Chaque exécution parcourt l'intégralité du catalogue et ne stocke que les nouvelles entrées ou les mises à jour.

- **Fréquence** : toutes les heures (cron : 0 * * * *)
- **Chemin MinIO** : s3://datalake/bronze/books/{source}/{YYYY}/{MM}/{DD}/{HH}/

4.2 Mode Streaming

Un producteur Kafka publie chaque enregistrement scrapé comme un événement indépendant sur un topic dédié.

- **Broker** : Apache Kafka
- **Topic** : books.raw.events
- **Sérialisation** : JSON

5 Infrastructure Docker

5.1 Composition des services

Le fichier `docker-compose.yml` orchestre l'ensemble des services nécessaires au pipeline Big Data.

Service	Port	Rôle
Zookeeper	2181	Gestionnaire de configuration pour Kafka
Kafka	9092	Broker de messages pour le mode streaming
MinIO	9000, 9001	Data Lake compatible S3
MySQL	3306	Data Warehouse relationnel
Redis	6379	Cache pour déduplication des URLs
Airflow Webserver	8080	Interface web de gestion des DAGs
Airflow Scheduler	-	Planificateur des DAGs
Streamlit	8501	Dashboard temps réel

TABLE 5.1 – Services Docker définis

☐		Name	Container ID	Image	Port(s)	Actions
☐	▼	projet-bigdata	-	-	-	
☐		redis	ab453b4de49c	redis:7-alpi	6450:6379	
☐		minio	e8df0f4919d7	minio/minio	9001:9001	
☐		mysql	ae8a325b7c5a	mysql:8.0	55000:3306	
☐		zookeeper	6859262d9164	confluentir	2181:2181	
☐		airflow-schec	429e85f073d9	apache/air		
☐		airflow-webs	3ce26086b261	apache/air	8082:8080	
☐		phpmyadmin	947d378a936a	phpmyadm	5050:80	
☐		superset	123f743674d1	apache/su	8089:8088	
☐		kafka_broker	e9f0543954af	confluentir	9092:9092	
☐		streamlit	60ad6746f5c1	python:3.1	8501:8501	

FIGURE 5.1 – Infrastructure conteneurisée

5.2 Commandes essentielles

Listing 5.1 – Commandes Docker essentielles

```
1 # Demarrer toute l'infrastructure
2 docker-compose up -d
3
4 # Verifier que tout tourne
5 docker ps
6
7 # Arrêter tout
8 docker-compose down
9
10 # Voir les logs d'un service
11 docker logs kafka
```

5.3 Interfaces web

Service	URL	Identifiants
MinIO Console	localhost :9001	minioadmin / minioadmin123
Airflow	localhost :8080	admin / admin123
Streamlit	localhost :8501	Aucun (dashboard public)

TABLE 5.2 – Interfaces web disponibles

6 Data Lake – MinIO

6.1 Organisation des buckets

-Le Data Lake est implémenté avec MinIO, une solution de stockage objet compatible.

Chemin	Couche	Contenu
datalake/bronze/books/	Bronze	JSON bruts issus du scraper
datalake/silver/books/	Silver	Parquet nettoyés et normalisés
datalake/gold/analytics/	Gold	Tables agrégées (Parquet)
datalake/logs/	Logs	Logs de pipeline, erreurs scraper
datalake/quarantine/	Quarantaine	Données invalides

TABLE 6.1 – Structure du Data Lake MinIO




FIGURE 6.1 – Interface MinIO Console après initialisation

7 Architecture Médaille

7.1 Schéma des couches

L'architecture Médaille organise les données en trois couches distinctes.



FIGURE 7.1 – Architecture Médaille Bronze/Silver/Gold

7.2 Couche Bronze – Données Brutes

La couche Bronze stocke les données telles qu'elles ont été collectées, sans aucune transformation.

- **Format** : JSON (un fichier par run)
- **Partitionnement** : source / année / mois / jour / heure
- **Validation** : aucune à ce stade
- **Rétention** : illimitée (historique complet)

7.3 Couche Silver – Données Nettoyées

La couche Silver applique les transformations suivantes :

1. Suppression du HTML résiduel dans les descriptions
2. Normalisation des prix : conversion en float numérique
3. Normalisation des auteurs : gestion des valeurs 'unknown'
4. Détection et normalisation de la langue (ISO 2 lettres)
5. Standardisation des catégories
6. Déduplication basée sur l'URL (conservation du plus récent)

7. Nettoyage des descriptions (déduplication et suppression des retours à la ligne)
8. Mise en quarantaine des lignes sans titre
9. Calcul du score de qualité (0-100)
10. **Format de sortie** : Parquet compressé (Snappy) partitionné par catégorie

7.3.1 Score de qualité

Le score de qualité est calculé selon les règles suivantes :

Critère	Pondération
Titre présent	20 points
Auteur présent	20 points
Prix présent	20 points
Note étoiles présente	20 points
Année publication présente	10 points
ISBN présent	10 points
Total	100 points

TABLE 7.1 – Calcul du score de qualité

7.3.2 Gestion de la quarantaine

Les lignes invalides (sans titre) sont automatiquement isolées dans un répertoire **quarantine/** pour analyse ultérieure sans perte de données.

7.4 Couche Gold – Tables Analytiques

La couche Gold contient des agrégations prêtes à l'emploi pour la visualisation.

Table Gold	Description / Métriques
kpi_par_categorie	Prix moyen/min/max, note moyenne, nombre de livres, total avis par catégorie (books_toscrape_com)
distribution_notes	Nombre de livres par note (1 à 5 étoiles), prix moyen par catégorie
top_livres_chers	Top 10 livres les plus chers par catégorie avec rang
kpi_par_auteur	Nombre de livres, nombre total d'avis, année min/-max par auteur (openlibrary_org)
livres_flat	Vue unifiée de tous les livres des deux sources (sans description)

TABLE 7.2 – Tables Gold produites

8 Orchestration – Apache Airflow

8.1 DAG unique implémenté

L'ensemble du pipeline Big Data est orchestré via un seul DAG Apache Airflow nommé `pipeline_books`. Ce DAG est exécuté quotidiennement à 02h00, une heure choisie pour éviter les pics de charge sur les serveurs sources et garantir la disponibilité des données pour les analystes en début de journée.

Le DAG `pipeline_books` orchestrate l'intégralité du flux de données, depuis la collecte jusqu'à la visualisation. Il est composé de six tâches organisées en trois phases distinctes :

1. **Phase de collecte** : deux tâches de scraping s'exécutent en parallèle pour le site Books to Scrape et `scrape_openlibrary` pour l'API Open Library. Cette exécution simultanée optimise le temps global du pipeline.
2. **Phase de transformation** : après la complétion des deux scrapers, la tâche nettoie et déduplique les données brutes JSON vers le format Parquet. Ensuite, `silver_to_gold` produit les tables analytiques agrégées.
3. **Phase de chargement et visualisation** : la tâche `gold_to_mysql` charge les données agrégées dans le Data Warehouse MySQL, suivie de `refresh_streamlit` qui rafraîchit le dashboard temps réel Streamlit pour refléter les dernières données collectées.

Le DAG intègre un mécanisme de reprise sur erreur avec deux tentatives automatiques espacées de cinq minutes, garantissant ainsi la résilience du pipeline face aux aléas réseau ou aux indisponibilités temporaires des sources. La configuration `catchup=False` évite l'exécution rétroactive des tâches lors d'ajouts ultérieurs, ce qui est essentiel pour un pipeline de scraping où les données historiques ne doivent pas être re-scrapées.

8.2 Tâches du DAG

Le DAG est composé des tâches suivantes :

Tâche	Description
scrape_books_toscrape	Scraping du site Books to Scrape
scrape_openlibrary	Scraping de l'API Open Library
bronze_to_silver	Transformation Bronze → Silver
silver_to_gold	Agrégation Silver → Gold
gold_to_mysql	Chargement Gold → MySQL
refresh_streamlit	Rafraîchissement dashboard Streamlit

TABLE 8.1 – Tâches du DAG `pipeline_books`

8.3 Orchestration du DAG

Listing 8.1 – Ordre d'exécution des tâches

```

1 # Les deux taches de scraping s'ex cutent en parall le
2 [scrape_books_toscrape, scrape_openlibrary] >> bronze_to_silver >>
  silver_to_gold >> gold_to_mysql >> refresh_streamlit

```

Étape	Parallélisme	Description
Étape 1	Parallèle	Scraping simultané des deux sources Books to Scrape et Open Library
Étape 2	Séquentielle	Transformation Bronze → Silver (après scraping complet)
Étape 3	Séquentielle	Agrégation Silver → Gold
Étape 4	Séquentielle	Chargement des données Gold vers MySQL
Étape 5	Séquentielle	Rafraîchissement du dashboard Streamlit

TABLE 8.2 – Ordre d'exécution des étapes

8.4 Récapitulatif du DAG

Propriété	Valeur
ID du DAG	pipeline_books
Description	Scraping + Bronze→Silver + Silver→Gold + Streamlit
Fréquence d'exécution	Quotidienne à 02h00 (schedule : 0 2 * * *)
Nombre de tentatives	2 (en cas d'échec)
Délai entre tentatives	5 minutes
Rattrapage (catchup)	Désactivé
Tags	bigdata, books, emsi

TABLE 8.3 – Récapitulatif des propriétés du DAG

8.5 Monitoring et alertes

- Interface web Airflow (port 8082) pour le suivi des runs et des logs
- Visualisation du graphe des dépendances
- Logs détaillés par tâche
- Métriques de pipeline : durée d'exécution, volume traité, taux d'erreur




FIGURE 8.1 – Interface web Apache Airflow – Vue du DAG pipeline_books




FIGURE 8.2 – Interface web Apache Airflow

8.6 Tests de qualité

Des contrôles de qualité sont implémentés avec Great Expectations après chaque étape de transformation.

Dimension	Test	Règle / Seuil
Complétude	Livre sans titre	titre IS NOT NULL (0 tolérance)
Complétude	Date scraping manquante	date_scraping IS NOT NULL
Validité	Prix négatif ou nul	prix > 0.0
Validité	Note hors plage	note BETWEEN 1 AND 5
Cohérence	URL invalide	url LIKE 'http%'
Cohérence	Description trop courte	len(description) ≥ 30
Unicité	Doublons par URL	url UNIQUE par run
Fraîcheur	Date trop ancienne	date_scraping > NOW() - 48h

TABLE 8.4 – Tests de qualité des données

9 Visualisation – Streamlit & Power BI

9.1 Introduction

La couche de visualisation constitue l’aboutissement du pipeline BookFlow. Elle repose sur deux outils complémentaires : **Streamlit** pour le monitoring temps réel du pipeline, et **Power BI** pour l’analyse métier approfondie. Les deux outils sont connectés au Data Warehouse MySQL alimenté depuis la couche Gold de MinIO.

9.2 Dashboards réalisés

Dashboard	Outil	Visualisations
Vue d’ensemble	Streamlit	KPIs globaux, top genres, distribution notes, disponibilité
Catalogue complet	Streamlit	Table interactive filtrée par genre, top livres chers
Vue principale	Power BI	KPIs, liste titres, navigation par catégorie/auteur
Analyse par catégorie	Power BI	Notes, prix min/max, prix moyen, nb livres par genre
Analyse par auteur	Power BI	Répartition livres, classement avis, table auteurs/langue

TABLE 9.1 – Dashboards réalisés dans BookFlow

9.3 Dashboards Streamlit




FIGURE 9.1 – Dashboard Streamlit BookFlow – Vue d'ensemble des KPIs

Description de la Figure 9.1. La première page du dashboard Streamlit BookFlow présente une vue synthétique de l'ensemble des données collectées et transformées. En haut de la page, quatre cartes KPI affichent les indicateurs globaux du pipeline : **510 livres** collectés au total, un **prix moyen de £35.65**, une **note moyenne de 2.9 étoiles sur 5**, et **43 genres** distincts identifiés dans le corpus.

Le graphique en barres horizontales intitulé *Top Genres par Nb Livres* révèle que les catégories *Unknown*, *Sequential Art* et *Mystery* sont les mieux représentées, avec respectivement plus de 60, 60 et 30 livres. Le camembert *Distribution des Notes* montre une répartition relativement équilibrée entre les cinq niveaux de notation, avec une légère dominance des notes 1 et 5 étoiles (25.1% chacune), traduisant une polarisation des avis lecteurs. L'histogramme vertical *Prix Moyen par Genre* met en évidence que les genres *Fantasy*, *Suspense*, *Classics* et *Novels* affichent les prix moyens les plus élevés, avoisinant £60, tandis que *Self-Help* et *Travel* sont les moins onéreux. Enfin, le graphique circulaire *Disponibilité* confirme que **74.3%** des livres sont disponibles en stock contre 25.7% au statut inconnu, validant la bonne couverture des données de disponibilité issues du scraping.




FIGURE 9.2 – Dashboard Streamlit BookFlow – Top Livres les Plus Chers et Catalogue Complet

Description de la Figure 9.2. La deuxième page du dashboard Streamlit se compose de deux sections complémentaires. La section supérieure, intitulée *Top Livres les Plus Chers*, présente un classement des 10 livres les plus chers du corpus sous forme de tableau avec les colonnes *titre*, *auteur*, *prix*, *note_etoiles* et *categorie*. On y observe notamment *Life Without a Recipe* (£59.04, note 5/5, Autobiography), *Approval Junkie* (£58.81, note 5/5, Autobiography) et *Ways of Seeing* (£39.51, note 5/5, Art), ce qui suggère que la catégorie *Autobiography* concentre les ouvrages les plus premium du catalogue.

La section inférieure présente le **Catalogue Complet** des 45 livres chargés dans le Data Warehouse MySQL, avec un filtre dynamique par genre permettant une navigation interactive. Chaque ligne du tableau affiche le titre, l'auteur, le prix, la note en étoiles, la catégorie et la langue de publication. L'ensemble des livres listés sont en langue anglaise (en), cohérent avec les sources ciblées. Cette vue catalogue constitue la table `livres_flat` chargée depuis la couche Gold de MinIO vers MySQL, représentant l'aboutissement complet du pipeline BookFlow.

9.4 Dashboards Power BI

Power BI Desktop est connecté directement au Data Warehouse MySQL via le connecteur ODBC (localhost :3307, base `books_dw`). Trois pages de tableaux de bord ont été réalisées, chacune exploitant les tables Gold chargées depuis MinIO.




FIGURE 9.3 – Power BI – Page principale : KPIs et catalogue des titres

Description de la Figure 9.3. La page principale du rapport Power BI, intitulée **BOOK-ANALYZE**, constitue le point d'entrée du tableau de bord analytique. Elle affiche en haut quatre indicateurs clés issus de la table `kpi_par_categorie` : **45 livres** au total (somme de `nb_livres`), un **prix moyen de £38.41**, une **note moyenne de 3.06 étoiles sur 5**, et **17 catégories** distinctes identifiées dans le Data Warehouse.

La partie centrale présente un tableau interactif des titres trié par ordre alphabétique décroissant, affichant pour chaque livre son titre et son année de publication issue de la table `livres_flat`. On y retrouve des œuvres classiques telles que *Walden* (1854), *Villette, a novel* (1853), *To the Lighthouse* (1927) ou encore *The War of the Worlds*. Cette table constitue un outil de navigation rapide pour l'utilisateur final. La barre latérale gauche propose deux boutons de navigation vers les pages analytiques dédiées : **Par catégorie** et **Par auteur**, assurant une expérience de navigation fluide et structurée.




FIGURE 9.4 – Power BI – Page analyse par catégorie : notes, prix et volumes

Description de la Figure 9.4. La page *Par catégorie* offre une analyse multidimensionnelle des genres littéraires à partir des tables `kpi_par_categorie` et `distribution_notes`. Elle se compose de quatre visualisations complémentaires.

Le graphique en barres horizontales *Moyenne de note_moyenne par catégorie* révèle que les genres *Adult Fiction*, *Art*, *Autobiography* et *New Adult* obtiennent les meilleures notes moyennes (proches de 5/5), tandis que *Science*, *Psychology* et *Paranormal* se situent en bas du classement. Les deux tableaux de droite présentent respectivement la *Somme de prix_max* (total 709.36) et la *Somme de prix_min* (total 606.36) par catégorie, permettant d'identifier les genres à forte amplitude tarifaire comme *Food and Drink* (max 59.92, min 11.05) versus les genres à prix unique comme *Adult Fiction* (max = min = 15.36).

Le camembert *Moyenne de prix_moyen par catégorie* illustre la répartition du prix moyen par genre, avec *Fantasy* (9%, £58.75) et *Horror* (8.41%) en tête. Enfin, l'histogramme *Somme de nb_livres par catégorie* confirme que *Unknown* et *Food and Drink* concentrent le plus grand nombre de livres (>15), tandis que la majorité des genres n'en contient qu'un ou deux.



FIGURE 9.5 – Power BI – Page analyse par auteur : répartition et avis

Description de la Figure 9.5. La page *Par auteur* exploite la table *kpi_par_auteur* pour fournir une analyse centrée sur les contributeurs du corpus. Elle se structure en quatre composantes visuelles.

Le graphique en anneau *Somme de nb_livres par auteur* représente la répartition des livres entre 54 auteurs identifiés. *Arthur Conan Doyle*, *Charlotte Brontë* et *Gilbert Keith Chesterton* dominent avec 3 œuvres chacun (5,56%), suivis de *Charles Dickens* et *Louisa May Alcott* avec 2 œuvres (3,7%). Le tableau de droite confirme cette répartition avec le total de **54 livres** répartis entre les auteurs référencés.

La table inférieure gauche liste l'ensemble des auteurs avec leur langue de publication, majoritairement l'anglais (**en**), ce qui est cohérent avec les sources Open Library et Books to Scrape. L'histogramme *Somme de nb_avis_total par auteur* est particulièrement révélateur : *Arthur Conan Doyle* arrive largement en tête avec plus de 2 500 avis cumulés, suivi de *William Shakespeare* et *Charlotte Brontë* avec environ 2 000 avis. Cette métrique, issue de la colonne *nb_avis_total* de la table Gold, permet d'identifier les auteurs les plus populaires auprès des lecteurs en ligne, indépendamment du nombre de titres publiés.

10 Planning Indicatif

Semaine	Tâche	Durée	Livrable partiel
S1	Analyse des besoins, choix de l'architecture, setup Docker	1 semaine	Architecture validée
S2	Développement du scraper + ingestion Kafka + MinIO Bronze	1 semaine	Scraper fonctionnel
S3	Pipeline ETL Bronze → Silver, tests qualité	1 semaine	Couche Silver OK
S4	Agrégations Gold, chargement MySQL	1 semaine	Couche Gold + DW
S5	Orchestration Airflow, DAGs complets	1 semaine	Tous DAGs actifs
S6	Dashboards Streamlit et Power BI, tests finaux	1 semaine	Dashboards livrés
S7	Rédaction rapport, préparation soutenance	1 semaine	Rapport + présentation

TABLE 10.1 – Planning prévisionnel

Conclusion

Ce cahier des charges définit l'ensemble des spécifications pour la réalisation de la plateforme Big Data de collecte et d'analyse de données livresques. Il couvre l'ensemble du pipeline, depuis la collecte par web scraping jusqu'à la visualisation des KPIs, en passant par l'ingestion, le stockage dans un Data Lake, la transformation selon l'architecture Médaillon, l'orchestration avec Airflow et la garantie de qualité des données.

Le respect de ces spécifications permettra de livrer une solution robuste, scalable et maintenable, répondant aux objectifs pédagogiques et techniques fixés par le module Architecture de Données.

Bibliographie

Documentation technique et ressources web

4. APACHE SOFTWARE FOUNDATION. *Apache Airflow Documentation*. Version 2.9. [En ligne]. Disponible : <https://airflow.apache.org/docs/> (Consulté le 10 avril 2026).
5. APACHE SOFTWARE FOUNDATION. *Apache Kafka Documentation*. Version 3.6. [En ligne]. Disponible : <https://kafka.apache.org/documentation/> (Consulté le 10 avril 2026).
6. MINIO. *MinIO Object Storage Documentation*. RELEASE.2024. [En ligne]. Disponible : <https://min.io/docs> (Consulté le 10 avril 2026).
7. SCRAPY. *Scrapy Documentation*. Version 2.11. [En ligne]. Disponible : <https://docs.scrapy.org/> (Consulté le 10 avril 2026).
8. PANDAS. *pandas documentation*. Version 2.x. [En ligne]. Disponible : <https://pandas.pydata.org/docs/> (Consulté le 10 avril 2026).
9. GREAT EXPECTATIONS. *Great Expectations Documentation*. Version 0.18. [En ligne]. Disponible : <https://docs.greatexpectations.io/> (Consulté le 10 avril 2026).
10. STREAMLIT. *Streamlit Documentation*. Version 1.35. [En ligne]. Disponible : <https://docs.streamlit.io/> (Consulté le 10 avril 2026).
11. MICROSOFT. *Power BI Documentation*. [En ligne]. Disponible : <https://learn.microsoft.com/power-bi/> (Consulté le 10 avril 2026).
12. DOCKER. *Docker Documentation*. Version 26. [En ligne]. Disponible : <https://docs.docker.com/> (Consulté le 10 avril 2026).
13. BOOKS TO SCRAPE. *Books to Scrape*. [En ligne]. Disponible : <http://bookstoscrape.com/> (Consulté le 10 avril 2026).
14. OPEN LIBRARY. *Open Library API Documentation*. [En ligne]. Disponible : <https://openlibrary.org/developers/api> (Consulté le 10 avril 2026).